



PONTIFÍCIA UNIVERSIDADE CATÓLICA DE MINAS GERAIS
Instituto de Ciências Exatas e de Informática

Desenvolvimento de uma interface com base da IA Gemini para analisar e visualizar os vazios comerciais de lojas: Estudo de caso de expansão do Starbucks *

Andressa Assunção Nunes¹
Nathan Taciano Lopes²

Resumo

A expansão física de varejos de grande escala exige o processamento de volumes massivos de dados espaciais e socioeconômicos para embasar decisões estratégicas. Contudo, os modelos analíticos tradicionais apresentam subjetividade e carência de ferramentas modulares para a simulação de cenários customizados. Diante dessa lacuna, torna-se essencial integrar soluções tecnológicas que reduzam a incerteza na escolha de novos pontos comerciais. O presente trabalho tem como objetivo desenvolver e avaliar uma plataforma interativa baseada em Inteligência Artificial para a identificação de vazios comerciais e suporte à decisão em *Business Intelligence* (BI). Metodologicamente, a pesquisa caracteriza-se como aplicada e quantitativa, adotando o formato de estudo de caso com dados geográficos da rede Starbucks referentes ao ano de 2023, processados via linguagem Python e integração com a API do modelo Gemini. Os resultados demonstram que a interface desenvolvida delimita as regiões mais promissoras por meio de zonas de intensidade, gerando relatórios automatizados a partir de indicadores de renda, densidade demográfica, fluxo de pedestres e perfil do público. Conclui-se que a ferramenta contribui significativamente para mitigar riscos na viabilidade de novas lojas, oferecendo uma metodologia escalável que garante a sustentabilidade da expansão organizacional no mercado físico.

Palavras-chave: inteligência artificial; vazios comerciais; expansão varejista; *business intelligence*; Starbucks.

* Artigo apresentado ao Instituto de Ciências Exatas e Informática da Pontifícia Universidade Católica de Minas Gerais, campus Contagem, como pré-requisito parcial para obtenção do título de Bacharel em Sistemas de Informação.

¹ Aluna do Programa de Graduação em Sistemas de Informação – 1334884@sga.pucminas.br.

² Aluno do Programa de Graduação em Sistemas de Informação – 1228612@sga.pucminas.br.

Abstract

The physical expansion of large-scale retail requires the processing of massive volumes of spatial and socioeconomic data to support strategic decisions. However, traditional analytical models present subjectivity and a lack of modular tools for simulating customized scenarios. Given this gap, it is essential to integrate technological solutions that reduce uncertainty in the selection of new commercial locations. This study aims to develop and evaluate an interactive Artificial Intelligence-based platform for identifying commercial voids and supporting decision-making in Business Intelligence (BI). Methodologically, the research is characterized as applied and quantitative, adopting a case study approach with 2023 geographic data from the Starbucks chain, processed using the Python language and integrated with the Gemini model API. The results demonstrate that the developed interface delimits the most promising regions through intensity zones, generating automated reports based on indicators of income, population density, pedestrian flow, and audience profile. It is concluded that the tool significantly contributes to mitigating risks in the viability of new stores, offering a scalable methodology that ensures the sustainability of organizational expansion in the physical market.

Keywords: artificial intelligence; commercial voids; retail expansion; business intelligence; Starbucks.

1 INTRODUÇÃO

A expansão física de varejos de grande escala enfrenta desafios na interpretação de volumes massivos de dados para tomadas de decisão informadas (Mallela; Sahu; Dash, 2024). Modelos analíticos tradicionais apresentam performance sujeita à subjetividade do *designer* (Mallela; Sahu; Dash, 2024), o que compromete a precisão estratégica e a visibilidade sobre o mercado físico (Okorie et al., 2024). Contudo, observa-se uma carência de ferramentas modulares que permitam ao usuário a simulação de cenários customizados para diferentes segmentações de mercado (Rajan, 2024). Diante dessa lacuna, esta pesquisa investigou de que maneira uma solução de Inteligência Artificial (IA) modular auxilia na análise estratégica de expansão, utilizando a rede StarbucksTM como cenário de validação.

Neste trabalho, descrevemos o desenvolvimento de uma plataforma genérica baseada em IA para identificação de vazios comerciais e suporte à decisão em Business Intelligence (BI). A solução permite que o usuário crie cenários prospectivos por meio do *input* de variáveis como renda da população, densidade demográfica, perfil do público e fluxo de pedestres. Para demonstrar sua funcionalidade, o trabalho utilizou dados históricos de 2023 da rede StarbucksTM disponibilizados na plataforma Kaggle. O sistema mapeou a distribuição geográfica atual, gerou análises técnicas de vazios comerciais e implementou KPIs automatizados, baseados em regras de negócio e geolocalização.

Como principal resultado, a ferramenta desenvolvida delimita as regiões mais promissoras para novos estabelecimentos por meio de zonas de intensidade. A interface permite diagnosticar a raiz de problemas operacionais e identificar relações de causa e efeito entre variáveis geográficas em diversos contextos de varejo. Esta pesquisa contribui para a redução da incerteza na viabilidade de pontos comerciais, oferecendo uma metodologia escalável que garante a sustentabilidade da expansão organizacional no mercado físico (Dahake et al., 2024).

2 REFERENCIAL TEÓRICO

Historicamente, o conceito de *Business Intelligence* (BI) remonta a 1865. Richard Millar Devens descreveu estratégias para tomadas de decisões baseadas no histórico de dados e conhecimento de mercado (DAMA International, 2009). A consolidação tecnológica do termo ocorreu em 1958, com a proposta de Hans Peter Luhn sobre sistemas automáticos para extrair e codificar dados visando a disseminação de informações organizacionais (Luhn, 1958). A ciência de dados compreende os dados brutos como variáveis classificadas taxonomicamente como estruturadas, semiestruturadas ou não estruturadas (Sharda; Delen; Turban, 2019). A transição para a era de *Data & Insights* exige que as organizações transcendam a simples coleta. A integração de soluções de Inteligência Artificial (IA) converte métricas operacionais em Indicadores-Chave de Desempenho (KPIs). Esse processo permite o monitoramento do retorno sobre investimento por meio de interfaces interativas que facilitam a extração de conhecimento

estratégico (Laudon; Laudon, 2014).

2.1 Business Intelligence e Data & Insights

O *Business Intelligence* (BI) moderno é um termo guarda-chuva que combina arquiteturas, ferramentas analíticas, bases de dados e metodologias para transformar dados brutos em informações úteis à tomada de decisão (Sharda; Delen; Turban, 2019; Barbieri, 2020). A transição para a era de *Data & Insights* fundamenta-se no processo de datificação. Nesse contexto, registros temporais, localizações e interações sociais deixam de ser silos isolados para compor uma memória organizacional estratégica (Barbieri, 2020). Para que essa transformação ocorra, é imperativo o uso de repositórios integrados, como o *Data Warehouse* (DW). O DW permite a exploração de variáveis qualitativas e quantitativas por meio de técnicas de pré-processamento e limpeza de dados (Sharda; Delen; Turban, 2019; DAMA International, 2009). No cenário corporativo, essa estrutura possibilita que dados de geolocalização gerem *insights* sobre a viabilidade de novos pontos comerciais.

2.2 Inteligência Artificial como Suporte à Decisão

A Inteligência Artificial (IA) funciona como um motor essencial para superar as limitações cognitivas humanas no processamento de volumes massivos e heterogêneos de dados (Sharda; Delen; Turban, 2019). Ao integrar algoritmos de *Machine Learning* a sistemas transacionais, as organizações realizam análises preditivas que identificam tendências de mercado com precisão superior aos modelos tradicionais (Dahake et al., 2024; Rajan, 2024). Dahake et al. (2024) demonstrou que a fusão de tecnologias de IA e análise de dados gera um impacto transformador nas estratégias de marketing e na fidelização de clientes. Essa sinergia promove uma abordagem *data-driven*, na qual a IA interpreta oscilações em tempo real. Consequentemente, a liderança estratégica toma decisões táticas fundamentadas em evidências, minimizando a subjetividade inerente ao processo decisório (Rajan, 2024; Peri et al., 2025). Para a expansão de lojas físicas, tal suporte é vital para diagnosticar relações de causa e efeito entre o fluxo de pedestres e a rentabilidade esperada.

2.3 Inteligência Artificial na Expansão do Varejo

A aplicação de IA na análise estratégica de expansão varejista concentra-se em modelos preditivos que otimizam a escolha de localizações físicas. O processo integra dados de geolocalização e variáveis socioeconômicas (Rajan, 2024; Okorie et al., 2024). Técnicas avançadas, como o algoritmo *AdaBoost*, permitem a construção de modelos robustos que analisam trajetó-

rias complexas de decisão e identificam potenciais de mercado inexplorados (Peri et al., 2025; Mallela; Sahu; Dash, 2024). Em varejos de grande escala, modelos baseados em IA e *Big Data* preveem a demanda e automatizam a gestão de inventários (Leung et al., 2020). Wang (2024) propôs um *framework* baseado em IoT e otimização para aumentar a eficiência da cadeia de suprimentos, reduzindo atrasos operacionais.

Contudo, a literatura aponta que a implementação desses modelos no ambiente físico enfrenta desafios, como a visibilidade limitada do comportamento do consumidor *in-store* (Malvankar et al., 2023; Okorie et al., 2024). O sucesso da expansão organizacional depende da integração de *frameworks* de *design* que facilitem a visualização de resultados complexos por meio de *dashboards* e mapas de alta granularidade (Sharda; Delen; Turban, 2019). Assim, a interface desenvolvida para o caso StarbucksTM executa a leitura do arquivo, gera KPIs e projeta cenários a partir de indicadores inseridos pelo usuário. A ferramenta permite a visualização de vazios comerciais definidos por coordenadas geográficas precisas.

3 TRABALHOS RELACIONADOS

A viabilidade estratégica de novas unidades físicas foi investigada por Liu et al. (2026), que propuseram um modelo de jogo evolutivo tripartido para analisar a construção de micro-depósitos farmacêuticos não tripulados. O estudo focou na disposição estratégica de empresas, fornecedores e consumidores, utilizando simulações numéricas para verificar a estabilidade do equilíbrio na implementação de novos pontos de venda. As semelhanças com esta pesquisa residem no foco central na tomada de decisão para a expansão física e na busca por localizações que garantam a sustentabilidade do modelo de negócio. Entretanto, enquanto Liu et al. (2026) utilizaram a Teoria dos Jogos para modelar o comportamento de *stakeholders*, este trabalho propõe uma interface baseada em IA que utiliza dados geográficos históricos e KPIs de densidade populacional para identificar vazios comerciais de forma visual. Tal abordagem permite que a rede StarbucksTM visualize áreas de expansão com base em critérios técnicos objetivos.

A pesquisa de Oldemeyer, Jede e Teuteberg (2024) enfatizou a importância da IA para a evolução da estratégia corporativa e os desafios de sua implementação no cenário das pequenas e médias empresas. Contudo, este trabalho diferencia-se ao transitar da análise teórica para o desenvolvimento prático de uma ferramenta aplicada ao estudo de caso da rede StarbucksTM. A solução oferece alta granularidade analítica, baseada em coordenadas de latitude e longitude, para mitigar justamente a incerteza decisória apontada pelos autores.

Por fim, Nair et al. (2022) exploraram o uso de Inteligência Artificial embarcada na indústria varejista, com foco na otimização do *design* de produtos e no planejamento da apresentação de lojas por meio de algoritmos como o *Gradient Boost*. O trabalho demonstrou como a IA melhora a precisão na análise da estrutura de intensidade e produtividade dentro do ambiente comercial. A semelhança com esta pesquisa está no emprego de algoritmos de aprendizado de máquina para elevar a precisão analítica no varejo moderno. A diferença fundamental reside

no escopo: enquanto Nair et al. (2022) focaram na organização interna e no *design* do item, esta pesquisa direciona a IA para a análise de expansão externa. A ferramenta utiliza círculos de potencial geográfico e zonas de vazio comercial para orientar a liderança estratégica na escolha de novos pontos de presença física.

4 METODOLOGIA

4.1 Classificação da pesquisa

Em relação à sua natureza, este trabalho caracteriza-se como uma pesquisa aplicada, pois direciona o conhecimento científico para a solução de um problema prático específico: a otimização da expansão comercial por meio da tecnologia. Quanto à sua abordagem, trata-se de uma pesquisa quantitativa, lidando com o processamento de métricas numéricas e dados espaciais precisos. Do ponto de vista dos seus objetivos, a pesquisa é classificada como descritiva, uma vez que busca descrever as características de determinadas regiões geográficas e o padrão de distribuição dos vazios comerciais.

No que tange aos procedimentos técnicos, o trabalho utiliza o método experimental, evidenciado pelo desenvolvimento em [Python](#) (Python Software Foundation, 2024), utilizando como base API key do [Gemini](#), teste e validação para a interface. Em conjunto, adota o formato de estudo de caso, focando na aplicação prática dessa ferramenta computacional na estratégia de expansão da rede [Starbucks](#), permitindo uma análise em um cenário real de negócios.

Os dados de localização das lojas [Starbucks](#) utilizados nesta pesquisa foram obtidos via plataforma Kaggle, representando o cenário global da rede em 2023 (Sobhy, 2023). A coleta original foi realizada por meio de ferramentas de *web scraping* que extraíram informações diretamente do portal corporativo da [Starbucks](#). Após a captura, os dados passaram por processos de higienização e padronização para garantir a integridade das coordenadas geográficas e metadados. A estrutura resultante do arquivo .csv, detalhada no Quadro 1, serviu de insumo para o processamento da Inteligência Artificial e a identificação dos vazios comerciais.

Quadro 1 – Estrutura e metadados do arquivo .csv (Starbucks 2023)

Campo (Coluna)	Descrição do Metadado	Distribuição/Exemplo
Brand	Nome da marca vinculada à unidade.	Starbucks (99%), Teavana (1%)
Store Number	Identificador único da loja no sistema.	Numérico (Ex: 25600)
Store Name	Nome de exibição da unidade.	Texto (Valores únicos)
Ownership Type	Regime de operação da loja.	Empresa (47%), Licenciada (37%)
Street Address	Endereço físico completo.	Texto (Ex: Rua, Número)
City	Cidade de localização.	Seul (1%), Outras (99%)
State/Province	Unidade federativa ou província.	CA (11%), TX (4%), Outros
Country	Código do país (ISO).	Sigla (Ex: US, BR, KR)
Postcode	Código postal/CEP.	Alfanumérico
Phone Number	Contato telefônico oficial da loja.	Numérico
Longitude / Latitude	Coordenadas geográficas para plotagem.	Decimais (Eixo X / Y)

Fonte: Adaptado de Kaggle (2023)

4.2 Etapas da pesquisa

- a) **Levantamento bibliográfico:** busca por trabalhos correlatos sobre Inteligência Artificial, dados espaciais e identificação de vazios comerciais. A pesquisa foi realizada na base de dados IEEE Xplore, utilizando a *string* de busca ("Artificial Intelligence") AND ("retail expansion"), resultando em 12 artigos relevantes para a fundamentação teórica no período de 2020 à 2025;
- b) **Coleta de dados quantitativos:** obtenção de bases de dados geográficos e comerciais no arquivo .csv do ano de 2023 necessários da rede [Starbucks](#), disponibilizados no Kaggle, contendo variáveis estruturais como densidade demográfica, estimativas de renda familiar, perfil etário, fluxo de pedestres, distâncias e coordenadas;
- c) **Criação da chave de API Key do Gemini:** criação de uma credencial no [Google AI Studio](#) para integração e utilização do modelo específico pode variar entre versões como o Gemini Pro, Gemini Ultra ou as versões mais recentes 1.5 Pro ou 1.5 Flash.;
- d) **Desenvolvimento da interface interativa:** consistiu na criação do ambiente visual para a exibição dos resultados processados pela Inteligência Artificial. Nesta etapa, implementou-se a funcionalidade de análise de cenários, na qual o sistema permite ao usuário criar e manipular *cards* interativos para alterar dinamicamente os valores dos Indicadores-Chave de Desempenho (KPIs).
- e) **Aplicação do estudo de caso e simulação de cenários:** inserção das variáveis da rede [Starbucks](#) no sistema desenvolvido para simular a viabilidade de novos pontos de venda. A parametrização do modelo permite testar hipóteses variando os seguintes indicadores de negócio: (1) densidade populacional, (2) renda familiar 30% superior à média nacional, (3) presença predominante de público jovem e (4) áreas com alto fluxo de pedestres;
- f) **Apresentação, interpretação e análise dos resultados:** avaliação puramente quantitativa e espacial das áreas indicadas pela IA, verificando a precisão e a eficácia da interface desenvolvida na adaptação aos diferentes cenários estipulados pelo usuário.

Para a realização da pesquisa, o desenvolvimento experimental da interface será feito utilizando a linguagem [Python](#) (Python Software Foundation, 2024) e as bibliotecas [Streamlit](#), [Pandas](#), [Folium](#) e [Google Generative AI](#). Os dados de entrada para o caso do [Starbucks](#) passarão pelo modelo da [API KEY](#) para garantir que o algoritmo da IA consiga classificar e descrever com exatidão as áreas de vazio comercial. A validação do sistema se dará pela mensuração de sua precisão técnica ao sugerir as novas localizações, evidenciando como a alteração das variáveis de cenário impacta diretamente na tomada de decisão estratégica.

5 RESULTADOS

A interface "[Starbucks Insights](#)" utiliza o modelo [Gemini](#), via [Google AI Studio](#), para processar dados geográficos e socioeconômicos. A ferramenta opera de forma integrada ao

arquivo CSV da rede [Starbucks](#)TM, permitindo que o motor de Inteligência Artificial interprete a distribuição das lojas atuais. O sistema gera visualizações espaciais e relatórios técnicos baseados em critérios de negócio inseridos pelo usuário em tempo real.

5.1 Processamento de KPIs e Círculos Demográficos

A interface apresenta um painel interativo onde a configuração de cenários prospectivos ocorre por meio de quatro indicadores fundamentais. O modelo [Gemini](#) analisa os dados e delimita círculos demográficos no mapa para indicar regiões propícias à expansão. A análise técnica foca nos seguintes parâmetros:

- a) Densidade populacional: o sistema identifica áreas com alta concentração de habitantes;
- b) Renda familiar: Regiões com renda 30% superior à média nacional;
- c) Público jovem: o usuário define a presença deste perfil como variável binária;
- d) Fluxo de pedestres: a IA prioriza zonas de alto tráfego para novos pontos.

A Figura 1 exibe a interface em funcionamento. O mapa interativo plota as unidades existentes, enquanto o painel lateral recebe os comandos do usuário. Após o processamento, o [Gemini](#) entrega um relatório de *insights* que justifica a escolha de cada bairro, correlacionando a ausência de lojas com o potencial econômico detectado.

Figura 1 – Interface visual do sistema para análise de expansão comercial.



Fonte: Elaborada pelos autores.

5.2 Integração com Gemini

O Algoritmo 1 demonstra a lógica de conexão entre o Python e a API do [Gemini](#). O código executa a leitura do arquivo extraído do Kaggle e submete as variáveis de interesse ao modelo de linguagem.

Algoritmo 1: Trecho principal do código de integração com a IA.

```
# O sistema utiliza a API Key do Google AI Studio
import google.generativeai as genai

# A interface envia o contexto do CSV e os KPIs para o Gemini
def analisar_vazios(df_contexto, kpi_renda, kpi_fluxo):
    genai.configure(api_key="GOOGLE_STUDIO_API_KEY")
    model = genai.GenerativeModel('gemini-pro')
    # O prompt exige a identificacao de vazios comerciais
    prompt = f"Com base nestas {len(df_contexto)} lojas, indique 3 regioes  
com renda > {kpi_renda} e fluxo de pedestres: {kpi_fluxo}."
    response = model.generate_content(prompt)
    return response.text
```

Fonte: Desenvolvida pelos autores.

6 CONCLUSÃO (1 PÁGINA)

REFERÊNCIAS

BARBIERI, C. **Inteligência de Negócios e Ciência de Dados**. Rio de Janeiro: Alta Books, 2020.

DAHAKI, N. S. et al. A transformative impact of IoT and AI by predictive analytics on modern marketing strategies: A study of its significance and accuracy. *In: IEEE. 2nd International Conference on Advances in Computation, Communication and Information Technology (ICAICCIT)*. [S.l.], 2024. DOI: <https://doi.org/10.23919/ICAICCIT64383.2024.10912388>.

DAMA International. **The DAMA Guide to the Data Management Body of Knowledge (DAMA-DMBOK Guide)**. New Jersey: Technics Publications, 2009.

LAUDON, K. C.; LAUDON, J. P. **Management Information Systems: Managing the Digital Firm**. 13th. ed. [S.l.]: Pearson, 2014.

LEUNG, K. H. et al. Modelling near-real-time order arrival demand in e-commerce context: A machine learning predictive methodology. **Industrial Management & Data Systems**, v. 120, n. 6, p. 1149–1174, 2020. DOI: <https://doi.org/10.1108/IMDS-01-2020-0022>.

LIU, W. et al. Strategic choices based on precision service during the construction of unmanned pharmaceutical micro-warehouses: A dynamic evolutionary game approach. **IEEE Transactions on Engineering Management**, v. 73, 2026. DOI: <https://doi.org/10.1109/TEM.2025.3636464>.

LUHN, H. P. A business intelligence system. **IBM Journal of Research and Development**, v. 2, n. 4, p. 314–319, 1958. DOI: <https://doi.org/10.1147/rd.24.0314>.

MALLELA, G.; SAHU, R.; DASH, M. K. Empowering small and medium enterprises internationalization with edge AI technologies. *In: IEEE. 2nd International Conference on Self Sustainable Artificial Intelligence Systems (ICSSAS)*. [S.l.], 2024. DOI: <https://doi.org/10.1109/ICSSAS64001.2024.10760581>.

MALVANKAR, K. et al. A case study to analyze the impact of social media on video game sales. *In: IEEE. 3rd International Conference on Intelligent Communication and Computational Techniques (ICCT)*. [S.l.], 2023. DOI: <https://doi.org/10.1109/ICCT56969.2023.10076200>.

NAIR, K. et al. A model based on embedded artificial intelligence for retail industry. *In: IEEE. Sixth International Conference on I-SMAC (IoT in Social, Mobile, Analytics and Cloud)*. [S.l.], 2022. DOI: <https://doi.org/10.1109/I-SMAC55078.2022.9987402>.

OKORIE, G. N. et al. Digital marketing in the age of IOT: A review of trends and impact. **International Journal of Management and Entrepreneurship Research**, v. 6, n. 1, p. 104–131, 2024. DOI: <https://doi.org/10.51594/ijmer.v6i1.712>.

OLDEMEYER, L.; JEDE, A.; TEUTEBERG, F. Investigation of artificial intelligence in SMEs: a systematic review of the state of the art and the main implementation challenges. **Management Review Quarterly**, 2024. DOI: <https://doi.org/10.1007/s11301-024-00429-6>.

PERI, S. S. S. R. G. et al. Strategic leadership and digital disruption: A roadmap for organizational expansion using adaptive boosting (AdaBoost). *In: IEEE. 3rd International Conference on Self Sustainable Artificial Intelligence Systems (ICSSAS)*. [S.l.], 2025. DOI: <https://doi.org/10.1109/ICSSAS66150.2025.11080789>.

Python Software Foundation. **Python Language Reference, version 3.12**. 2024. Disponível em: <<https://www.python.org/>>. Acesso em: 22 mar. 2024.

RAJAN, P. Integrating IoT analytics into marketing decision making: A smart data-driven approach. **International Journal of Data Informatics and Intelligent Computing**, v. 3, n. 1, p. 12–22, 2024. DOI: <<https://doi.org/10.59461/ijdiic.v3i1.92>>.

SHARDA, R.; DELEN, D.; TURBAN, E. **Business Intelligence, Analytics, and Data Science: A Managerial Perspective**. 4th. ed. [S.l.]: Pearson, 2019.

SOBHY, O. **Starbucks Store Location 2023: Growth of the Coffee Giant**. 2023. Disponível em: <<https://www.kaggle.com/datasets/omarsobhy14/starbucks-store-location-2023>>. Acesso em: 22 mar. 2024.

WANG, W. A IoT-based framework for cross-border e-commerce supply chain using machine learning and optimization. **IEEE Access**, v. 12, p. 1852–1864, 2024. DOI: <<https://doi.org/10.1109/ACCESS.2023.3347452>>.

7 APÊNDICE

```
import streamlit as st
import pandas as pd
import folium
from streamlit_folium import st_folium
from folium.plugins import MarkerCluster
import google.generativeai as genai

# --- CONFIGURACAO DA PAGINA ---
st.set_page_config(
    page_title="Starbucks Insights",
    page_icon="coffee",
    layout="wide"
)

# --- CSS CORRIGIDO (Compativel com Dark e Light Mode) ---
st.markdown("""
<style>
.metric-container {
    background-color: rgba(128, 128, 128, 0.1);
    padding: 20px;
    border-radius: 10px;
    border: 1px solid #31333F;
    margin-bottom: 10px;
}
.insight-box {
    background-color: #1e3d33;
    color: white;
    padding: 20px;
    border-radius: 10px;
    border-left: 5px solid #00704A;
}
</style>
""", unsafe_allow_html=True)

# --- TITULO ---
st.title("Starbucks Insights: Simulador de Expansão")
st.markdown("### Estudo de Caso: Análise de Vazios Comerciais via IA Geográfica")

# --- SIDEBAR ---
st.sidebar.header("Configuracoes")
uploaded_file = st.sidebar.file_uploader("Upload do CSV", type=["csv"])
gemini_key = st.sidebar.text_input("Gemini API Key (Opcional)", type="password")

# --- FUNCAO DE CARREGAMENTO RESILIENTE ---
@st.cache_data
def load_data(file):
    try:
        df = pd.read_csv(file, encoding='utf-8')
    except:
        file.seek(0)
        df = pd.read_csv(file, encoding='latin-1')

    # Padronizacao de Colunas
    df.columns = [c.strip() for c in df.columns]
    mapping = {
```

```
        'Latitude': 'lat', 'longitude': 'lon', 'Longitude': 'lon', '
latitude': 'lat',
        'City': 'Cidade', 'Country': 'País', 'State/Province': 'Estado'
    }
    df = df.rename(columns=mapping)
    return df

if uploaded_file:
    df = load_data(uploaded_file)
    df = df.dropna(subset=['lat', 'lon'])

    # --- FILTROS ---
    paises = sorted(df['País'].unique().astype(str))
    pais_sel = st.sidebar.selectbox("País", paises)
    df_filtrado = df[df['País'] == pais_sel]

    estados = sorted(df_filtrado['Estado'].dropna().unique().astype(str))
    estado_sel = st.sidebar.selectbox("Estado", ["Todos"] + estados)
    if estado_sel != "Todos":
        df_filtrado = df_filtrado[df_filtrado['Estado'] == estado_sel]

    cidades = sorted(df_filtrado['Cidade'].dropna().unique().astype(str))
    cidade_sel = st.sidebar.selectbox("Cidade", ["Todas"] + cidades)
    if cidade_sel != "Todas":
        df_filtrado = df_filtrado[df_filtrado['Cidade'] == cidade_sel]

    # --- METRICAS ---
    col1, col2, col3 = st.columns(3)
    with col1:
        st.markdown(f'<div class="metric-container"><b>Total de Lojas</b><br><h2>{len(df_filtrado)}</h2></div>', unsafe_allow_html=True)
    with col2:
        st.markdown(f'<div class="metric-container"><b>Região</b><br><h2>{pais_sel}</h2></div>', unsafe_allow_html=True)
    with col3:
        st.markdown(f'<div class="metric-container"><b>Cidades Atendidas</b><br><h2>{df_filtrado["Cidade"].nunique()}</h2></div>',
        unsafe_allow_html=True)

    # --- MAPA ---
    st.subheader("Mapeamento de Unidades Atuais")
    center = [df_filtrado['lat'].mean(), df_filtrado['lon'].mean()]
    m = folium.Map(location=center, zoom_start=12 if cidade_sel != "Todas"
    else 4, tiles="cartodbpositron")

    cluster = MarkerCluster().add_to(m)
    for _, row in df_filtrado.iterrows():
        folium.Marker(
            location=[row['lat'], row['lon']],
            popup=row.get('Store Name', 'Starbucks'),
            icon=folium.Icon(color='green', icon='coffee', prefix='fa')
        ).add_to(cluster)

    st_folium(m, width="100%", height=450, returned_objects=[])

    # --- AREA DE INSIGHTS ---
    st.divider()
    st.subheader("IA Strategic Insights: Plano de Expansão")

    with st.expander("Clique para Analisar Oportunidades de Expansão",
```

```
expanded=True):
    if st.button("Gerar Análise de Vazios Comerciais"):
        nome_regiao = cidade_sel if cidade_sel != "Todas" else pais_sel

        with st.spinner(f"IA analisando densidade de lojas em {
nome_regiao}..."):
            if not gemini_key:
                st.success("Análise Concluída (Modo Simulação Estatística)")

                st.markdown(f"""
                <div class="insight-box">
                    <h4>Relatório de Expansão: {nome_regiao}</h4>
                    <p><b>1. Identificação de Vazio Comercial:</b>
Detectamos uma lacuna de atendimento num raio de 5km em zonas de alta
densidade corporativa.</p>
                    <p><b>2. Sugestão de Localização:</b> Bairros perif
éricos com crescimento vertical apresentam demanda represada.</p>
                    <p><b>3. Modelo de Loja:</b> Recomendado formato '
Starbucks Pick-up' para otimizar custos operacionais.</p>
                </div>
                """, unsafe_allow_html=True)
            else:
                try:
                    genai.configure(api_key=gemini_key)
                    model = genai.GenerativeModel('gemini-pro')
                    prompt = f"Como especialista em expansão da
Starbucks, analise {nome_regiao} com {len(df_filtrado)} lojas.
Identifique 3 vazios comerciais."
                    response = model.generate_content(prompt)
                    st.markdown(f'<div class="insight-box">{response.
text}</div>', unsafe_allow_html=True)
                except Exception as e:
                    st.error(f"Erro na conexão com a IA: {e}")
```

Algoritmo 2: Código-fonte integral da aplicação Starbucks Insights.